



P R E V I S Ã O D E S A T I S F A Ç Ã O

em E-commerce com Dados Multimodais

Texto + Imagens + Dados Estruturados

01

O Problema



Contexto

Um marketplace recebe milhares de produtos. O gerente precisa decidir quais precisam de intervenção antes que as vendas caiam.



Solução

Sistema de IA que prevê a nota (1 a 5 estrelas) que um produto receberá, analisando o anúncio antes mesmo de ser publicado.

Como funciona

Preço + Categoria + Texto da Review + Foto do Produto → IA prevê: 1★ 2★ 3★ 4★ 5★

O gerente age ANTES do problema — ajusta preço, melhora a foto, revisa a descrição.



Estruturados

Preço, desconto, categoria,
avaliações anteriores.
~10 features numéricas.



Texto (NLP)

Título e conteúdo da review.
Sentimento, palavras-chave.
~50 features textuais.



Imagem (CV)

Foto do produto.
Nitidez, brilho, cores.
~6 features visuais.

Dataset: Amazon Sales (Kaggle)

1.351

Produtos

1.194

Reviews

500

Fotos
processadas

87

Features
no modelo

03

Arquitetura

MinIO

Armazenamento
(S3 mock)

PostgreSQL

Banco de dados
(Snowflake mock)

Airflow

Orquestrador
(DAG 8 etapas)

Metabase

Dashboard
(4 painéis)

Python Scripts (ingestão, NLP, CV, ML)


dbt-core: staging → dimensões → fatos → tabela ML pronta

Tudo sobe com: **docker compose up**

Troca DEV → PROD: 4 variáveis no .env | MinIO → AWS S3 | PostgreSQL → Snowflake

04

Pipeline ELT (8 Etapas)



⚡ NLP e CV rodam em paralelo (independência entre texto e imagem)

Orquestração — Apache Airflow

DAG (Directed Acyclic Graph): arquivo Python que define o que roda, em qual ordem e com quais dependências. Agenda diária ou execução manual.



NLP — Análise de Texto

VADER: sentimento do texto (-1 a +1)

-
- TF-IDF: palavras mais importantes
-
- Regex: detecta reclamação, elogio,
- menção a preço e entrega



CV — Análise de Imagem

OpenCV: nitidez, brilho, saturação

-
- Canny Edge: densidade de bordas
-
- Hipótese: fotos escuras ou borradas
- estão ligadas a ratings piores?

500 fotos de produtos processadas com OpenCV

300x300

Tamanho
médio

158.6

Brilho
médio

1.234

Blur score
médio



Naive Bayes

Classificação multiclasse
Prevê rating de 1 a 5 estrelas
baseado em ~87 features
combinando texto + imagem + preço.



Dupla implementação

Hard-code: algoritmo do zero
(Python puro + NumPy)

-
- Sklearn: MultinomialNB
(biblioteca scikit-learn)

Comparação & Métricas

Acurácia

Precisão

Recall

F1-Score

Matriz de Confusão

Tempo de Treino

Resumo Executivo

3 KPIs no topo: total de produtos,
rating médio, % reviews negativas

-
- Gráfico: rating por categoria
-
- Gráfico: polaridade (sentimento)
do texto vs rating
-
- Tabela: top 10 piores produtos
-
- Palavras mais relevantes
para reviews nota 5
-

Configuração automática

Conexão com banco

-
- 10 perguntas SQL
-
- Painel montado
em 1 comando
-

make up

Nuvem — AWS & Snowflake



CloudFormation (YAML)

S3: armazenamento de dados

-
- EC2: servidor do Airflow
-
- ECS: containers dbt + scripts
-
- SageMaker: treino do modelo
-
- Redshift: data warehouse

Dev → Prod

4 variáveis no .env

MinIO (local) → AWS S3

PostgreSQL → Snowflake

Airflow local → EC2

Metabase local → QuickSight

Nenhum código muda. Só o destino dos dados.

Scripts Python: boto3 (compatível MinIO e S3)

dbt: profiles.yml com targets dev (Postgres) e prod (Snowflake)

Basta trocar o .env e rodar make pipeline novamente.

Conclusão

Entregue

Pipeline ELT completo (8 etapas)

-
- NLP + Visão Computacional
-
- Naive Bayes hard-code + sklearn
-
- Dashboard Metabase automático
-
- CloudFormation + integração AWS

Próximos passos

Treinar modelo com dados reais

-
- Dataset com mais notas extremas
-
- Balanceamento de classes
-
- Relatório final + apresentação
-
- Testar com S3 e Snowflake reais

Stack: Python · Docker · Airflow · dbt · PostgreSQL · MinIO · Metabase · AWS · Snowflake

Disciplinas: Aprendizagem de Máquina · Cloud Computing · Modelagem de Dados para IA